Report 14

Part 1: Course exercises

- 1.1: 词形还原
- 1.2: 词性标注
- 1.3: 停用词
- 1.4: NLTK
- 1.5: 精确
- 2.1: F
- 2.2: T
- 2.3: F
- 2.4: F
- 2.5: F
- 3.1: D
- 3.2: ABCD
- 3.3: D
- 3.4 A
- 3.5: B

计算机 22A4 2022015232 孙春辉 2025 年 4 月 10 日 星期四 第九次作业

4.1: 文本预处理的基本流程包括分词、词形统一化、删除停用词。

4.2:

- 1、 对文本进行分词操作,从中找出正向情感词、负向情感词、否定词以及程度副词。
- 2、判断每个情感词之前是否有否定词及程度副词,将它之前的否定词和程度副词划分为一
- 组。如果存在否定词,则将情感词的情感权值乘以-1;如果有程度副词,就乘以程度副词的程度值。
- 3、将所有组的得分加起来,得分大于0的归于正向,小于0的归于负向。

Part 2:

Re-implement the codes from the product evaluation analysis Demo in the text book page 249-253 summarize the results and screenshot the codes in the report.

```
import jieba
import pandas as pd
from nltk import FreqDist
from matplotlib import pyplot as plt
from wordcloud import WordCloud

file_path = open('./商品评价信息.csv')
file_data = pd.read_csv(file_path)
# print(file_data)
file_data.drop(file_data[file_data['评价信息'] == '此用户没有填写评价。
'].index,inplace=True)
# print(file_data)

cut_words = jieba.lcut(str(file_data['评价信息'].values),cut_all = False)
print(cut_words)

stop_path = open('./停用词表.txt',encoding='utf-8')
```

```
stop words =stop path.read()
new_data = []
      new data.append(word)
print(new_data)
freq_list = FreqDist(new_data)
most common words = freq list.most common()
print(most_common_words)
font = r'C:\Windows\Fonts\STXINGKA.TTF'
wc = WordCloud(font path = font, background color = 'white', width =
1000, height = 800).generate(" ".join(new data))
plt.imshow(wc)
plt.axis('off')
plt.show()
Prefix dict has been built successfully.
「<del>'「' "</del>'", '穿', '上', '挺舒服', '的', ', '是', '我', '有史以来', '在', '网上'
[('衣服', 3), ('买', 2), ('喜欢', 2), ('裤子', 2), ('男朋友', 2), ('比较', 2),
Process finished with exit code 0
```

Part 3:

从 Moodle 下载'Report9-习近平在北京大学师生座谈会上的讲话.txt'文件并生成词云,具体方法参考本章节最后的实例以及网络资源,要求词云中不同频率的重点词语用不同颜色和字体大小进行显示,词云的形状要求贴合讲话内容,制作出的词云要求美观、大气、生动,如果是动态词云可加分。

```
import jieba
import matplotlib.pyplot as plt
def generate dynamic wordcloud(word freq, output path):
```

计算机 22A4 2022015232 孙春辉 2025 年 4 月 10 日 星期四 第九次作业

```
width=1000, # 设置画布宽度
  height=700, # 设置画布高度
def update(frame):
```

计算机 22A4 2022015232 孙春辉 2025 年 4 月 10 日 星期四 第九次作业

